Cyprus University of Technology | Department of Electrical Engineering and Computer Engineering and Informatics

CSE 473/525: Επιστήμη Δεδομένων

Διδάσκων: Σίμος Γερασίμου

ΟΜΑΔΙΚΗ ΕΡΓΑΣΙΑ ΕΞΑΜΗΝΟΥ

Ημ. Παράδοσης Φάσης Α': Δευτέρα, 30/03/2026

Ημ. Παράδοσης Φάσης Β': Δευτέρα, 27/04/2026

Ημ. Παρουσίασης Φάσης Α': Τρίτη, 31/03/2026

Ημ. Παρουσίασης Φάσης Β': Τρίτη, 28/04/2026

Στόχος του Project

Είστε μέλος της ομάδας DataVision η οποία έχει αναλάβει την εκπόνηση ενός έργου Data Science (Επιστήμης Δεδομένων). Το έργο αποσκοπεί στη σχεδίαση, ανάπτυξη και παρουσίαση μιας ολοκληρωμένης λύσης επιστήμης δεδομένων, από την αρχή ως την υλοποίηση.

Εργαζόμενοι σε ομάδες 3-4 ατόμων, θα υλοποιήσετε κάθε φάση του κύκλου επιστήμης δεδομένων, από τη διατύπωση ερευνητικού ερωτήματος έως την παράδοση ενός λειτουργικού πρωτοτύπου που υποστηρίζει την λήψη αποφάσεων σε πραγματικό χρόνο.

Το έργο είναι (εσκεμμένα) αρκετά ευρύ. Η ομάδα σας πρέπει να επιλέξει ένα τομέα ενδιαφέροντος, όπως για παράδειγμα σχετικό με το περιβάλλον, δημόσια υγεία, αθλητισμό, χρηματοοικονομικά, μεταφορές. Το τελικό αποτέλεσμα πρέπει να είναι ένα λειτουργικό πρωτότυπο εργαλείο που ενσωματώνει συλλογή δεδομένων, αποθήκευση, μοντελοποίηση και παρακολούθηση σε ένα ενιαίο και συνεκτικό σύστημα. Συγκεκριμένα, το σύστημα μπορεί να είναι webpage (διαδικτυακή εφαρμογή), mobile application (εφαρμογή), dashboard (διαδραστικός πίνακας ελέγχου) που επιδεικνύει μια συνεχή ροή δεδομένων (pipeline) και προβλεπτικές ικανότητες.

Υλοποίηση του κύκλου επιστήμης δεδομένων

Όπως έχουμε δει στο μάθημα, οι data scientists σπάνια ασχολούνται με μεμονωμένες εργασίες. Οι μελλοντικοί εργοδότες σας αναμένουν αποφοίτους που σκέφτονται ολοκληρωμένα, δηλαδή που κατανοούν όχι μόνο το πώς εκπαιδεύεται ένα μοντέλο, αλλά και γιατί τα δεδομένα συλλέχτηκαν, πώς αποθηκεύονται, τι υποθέσεις υποκρύπτει το μοντέλο και πώς η απόδοσή του υποβαθμίζεται με την πάροδο του χρόνου.

Στάδια του Κύκλου Ανάλυσης Δεδομένων

Η εργασία σας πρέπει να καλύπτει ξεκάθαρα τα παρακάτω στάδια του κύκλου ανάλυσης δεδομένων. Κάθε στάδιο πρέπει να τεκμηριωθεί καταλλήλως μέσα από τα τεχνικά παραδοτέα (έγγραφα, παρουσίαση, πρωτότυπο).

#	Στάδιο	Περιγραφή
1	**Αναγνώριση Ερώτησης**	• Ορίστε ένα σαφές και μετρήσιμο πρόβλημα. • Διατυπώστε υποθέσεις και διερευνητικές ερωτήσεις που μπορούν να απαντηθούν μέσω της εκτέλεσης ενός data science project.
2	**Συλλογή Δεδομένων**	• Συλλέξτε δεδομένα (μέσω έρευνας, web scraping, κλήσεις σε API) • Αναλύστε και τεκμηριώστε τις πηγές σας και τυχόν ηθικά ζητήματα
3	**Αποθήκευση Δεδομένων**	• Σχεδιάστε και υλοποιήστε μια βάση δεδομένων για την αποθήκευση των δεδομένων σας. Συμπεριλάβετε διάγραμμα ER ή/και σχήμα. • Επιλέξτε σχεσιακή (PostgreSQL, MySQL, SQLite) ή μη σχεσιακή (MongoDB, Firebase) βάση δεδομένων.
4	**Επεξεργασία Δεδομένων**	• Καθαρίστε, μετασχηματίστε και διαμορφώστε χαρακτηριστικά από τα ακατέργαστα δεδομένα.
5	**Ποιότητα Δεδομένων**	• Εφαρμόστε μέτρα για την ασφάλιση της ποιότητας των δεδομένων. • Αντιμετωπίστε καταλλήλως missing data και outliers.
6	**Μοντελοποίηση Δεδομένων**	• Κατασκευάστε και αξιολογήστε statistical και ML models (supervised και unsupervised, i.e., regression, classification, clustering) • Παρουσιάστε μετρικές και αναγνωρίστε τους περιορισμούς του μοντέλου.
7	**Παρουσίαση Δεδομένων**	• Αναπτύξτε ένα λειτουργικό πρωτότυπο (dashboard, web application, mobile application) που επιτρέπει στους χρήστες να εξερευνούν δεδομένα και να βλέπουν τα αποτελέσματα των μοντέλων.
8	**Παρακολούθηση & Αναθεώρηση**	• Εφαρμόστε στρατηγικές παρακολούθησης για ανίχνευση concept drift ή data drift με την πάροδο του χρόνου. • Υλοποιήστε τεχνικές αναθεώρησης των μοντέλων.

Φάσεις Project & Παραδοτέα

Το project χωρίζεται σε 2 φάσεις

<u>Φάση Α (20 μονάδες) – Project initialisation and early prototype:</u>

<u>Στόχος</u>: Στην πρώτη φάση του έργου αναμένεται να έχετε δημιουργήσει την ομάδα σας, να έχετε επιλέξει τον τομέα του έργου και να έχετε κάνει τον αρχικό σχεδιασμό της λύσης σας και του πρωτοτύπου.

Ο αρχικός σχεδιασμός αναμένεται να περιέχει (α) την ολοκλήρωση του σταδίου 1, (β) τουλάχιστον προπαρασκευαστικές ενέργειες για τα στάδια 2 και 3, και (γ) εμπεριστατωμένη ανάλυση πως θα υλοποιηθούν τα επόμενα στάδια του έργου.

- Μπορείτε φυσικά μαζί με την ομάδα σας να προχωρήσετε με τα επόμενα στάδια ώστε να έχετε περισσότερο χρόνο για ανάλυση των δεδομένων και βελτίωση των μοντέλων σας.
- Νοείται ότι υπάρχει η δυνατότητα για περαιτέρω βελτίωση των σταδίων που έχουν ολοκληρωθεί στη Φάση Α του έργου κατά τη διάρκεια της Φάσης Β (π.χ., καινούρια δεδομένα έχουν ανευρεθεί, ένα καλύτερο σχήμα της βάσης έχει δημιουργηθεί από την ομάδα).

Ημερομηνία Παράδοσης: Δευτέρα 30/03/2026, 23:59

Παραδοτέα (Moodle):

- Report PDF (4–5 σελίδες), επεξήγηση τομέα και έργου δεδομένων, επιλογών για τα υλοποιημένα στάδια του έργου, εφαρμογή, αρχικά διαγράμματα του πρωτοτύπου (database, user interface), σενάρια και configurations που θα υποστηρίζει το πρωτότυπο, ηθικές πτυχές δεδομένων
    - Το report πρέπει απαραίτητα να περιλαμβάνει link σε private/public GitHub repo (αν είναι private, αναμένεται να κάνετε invite το username 'gerasimou')
    - Το GitHub repo πρέπει να περιλαμβάνει documentation και οδηγίες εγκατάστασης
- Παρουσίαση για τη Φάση Α

Φάση Β (30 μονάδες) – Final working prototype:

Στόχος: Στη δεύτερη φάση του έργου αναμένεται να υλοποιήσετε το τελικό πρωτότυπο του έργου σας το οποίο υλοποιεί όλα τα στάδια του κύκλου ανάλυσης δεδομένων. Το τελικό πρωτότυπο είναι το κεντρικό στοιχείο της υποβολής σας. Αναμένεται να είναι ένα λειτουργικό και διαδραστικό εργαλείο σε μορφή της δικής σας επιλογής (dashboard, web application, mobile application).

Ημερομηνία Παράδοσης: Δευτέρα 27/04/2026, 23:59

Παραδοτέα (Moodle):

- Report PDF (4–5 σελίδες), αναθεώρηση (αν χρειάζεται) του τομέα και έργου δεδομένων, επιλογών για κάθε τα υλοποιημένα στάδια του έργου, εφαρμογή, τελικά διαγράμματα του πρωτοτύπου (database, user interface), σενάρια και configurations που υποστηρίζει το πρωτότυπο, ηθικές πτυχές δεδομένων.
    - Το report πρέπει απαραίτητα να περιλαμβάνει link σε private/public GitHub repo (αν είναι private, αναμένεται να κάνετε invite το username 'gerasimou')
    - Το GitHub repo πρέπει να περιλαμβάνει documentation και οδηγίες εγκατάστασης
- Παρουσίαση για τη Φάση Β

Περίληψη Παραδοτέων και Ημερομηνίες Παράδοσης

Part	Ημερομηνία Παράδοσης	Περιγραφή
A	**30/03/2026**	• Report PDF (4–5 σελ.): σχεδιασμός του έργου και αρχικό πρωτότυπο
		• Παρουσίαση part A (conceptual design & early prototype) & διαφάνειες
B	**27/04/2026**	• Report PDF (4–5 σελ.): τελική ανάλυση έργου και τελικό πρωτότυπο
		• Παρουσίαση part B (final prototype) & διαφάνειες

Αξιολόγηση & Βαθμολόγηση

Η εργασία αντιστοιχεί στο 100% της βαθμολογίας του μαθήματος για την ομαδική συνεισφορά. Οι ατομικές συνεισφορές αξιολογούνται μέσω συντελεστή αξιολόγησης από την ομάδα και ατομικές ερωτήσεις κατά τις παρουσιάσεις.

Αξιολόγηση Ομάδας: Κάθε μέλος ομάδας πρέπει να υποβάλει μια αξιολόγηση (peer assessment) για κάθε μέλος της ομάδας, συμπεριλαμβανομένου του εαυτού του. Η αξιολόγηση θα αποτελείται από μια βαθμολογία από 0 έως 10 για τη σημασία της συμβολής του μέλους της ομάδας, καθώς και από μια ευκαιρία για ανοιχτά σχόλια σχετικά με την απόδοση των μελών της ομάδας. Αυτές οι πληροφορίες θα υποβάλλονται **εμπιστευτικά μέσω ηλεκτρονικής έρευνας** που θα ανακοινωθεί στην ιστοσελίδα του μαθήματος λίγο μετά την προθεσμία υποβολής κάθε Φάσης. Η μη υποβολή έγκυρων αξιολογήσεων θα έχει ως αποτέλεσμα μηδενική βαθμολογία για το στοιχείο της αξιολόγησης του βαθμού του υποβάλλοντος φοιτητή.

Κατά τη βαθμολόγηση των αξιολογήσεων, η ομάδα βαθμολόγησης θα εξετάσει τις εκθέσεις αξιολόγησης. Εάν η ομάδα βαθμολόγησης έχει αμφιβολίες για το επίπεδο συμβολής ενός φοιτητή στο έργο, μπορεί να ζητήσει και να εξετάσει περαιτέρω αποδεικτικά στοιχεία (π.χ. συνεισφορές σε κώδικα και παραδοτέα, πρακτικά συνεδριάσεων της ομάδας) ή/και να καλέσει τον φοιτητή σε συνέντευξη, για να διαπιστώσει εάν εφαρμόζεται ατομική ποινή. Εάν από όλα αυτά τα στοιχεία κριθεί ότι ο φοιτητής δεν συμμετείχε στο ομαδικό έργο με παραγωγικό και ουσιαστικό τρόπο, θα υπάρξει ποινή από τη συνολική βαθμολογία του φοιτητή στην αξιολόγηση.

Ηθικοί & Πρακτικοί Περιορισμοί

Data Ethics Περιορισμοί

- Απαγορεύεται η συλλογή προσωπικά αναγνωρίσιμων πληροφοριών χωρίς ρητή συγκατάθεση. Αν διεξάγετε έρευνα, πρέπει να υποβάλετε ηθική δήλωση πριν από τη συλλογή δεδομένων.
- Αναφέρετε όλες τις πηγές δεδομένων, είτε αυτές προέρχονται από third-part APIs ή open data.
- Αποφύγετε τη μεροληπτική συλλογή δεδομένων ή δεδομένων με επιβλαβή περιεχόμενο. Αν υπάρχει προκατάληψη, τεκμηριώστε την και αντιμετωπίστε την στις επιλογές μοντελοποίησης.

Τεχνικοί Περιορισμοί

- Απαγορεύονται ιδιόκτητα εργαλεία που δεν μπορούν να κοινοποιηθούν.
- Το πρωτότυπο πρέπει να μπορεί να εκτελείται τοπικά σε laptop χωρίς GPU, ή να αναπτυχθεί σε cloud service δωρεάν tier φιλοξενίας (Streamlit Cloud).
- Το Git repository σας πρέπει να δείχνει ιστορικό commit με συνεισφορές από τα μέλη της ομάδας.

Προτεινόμενες Τεχνολογίες

ID	Περιγραφή
User Interface	PHP, Streamlit, Dash (Plotly), React/Vue
Logical Part	Python (Flask ή FastAPI), Node.js.
Database	PostgreSQL, MongoDB, SQLite.
Modelling	scikit-learn
Versioning	GitHub or similar

Προτεινόμενοι Ρόλοι Ομάδας

Οι παρακάτω ρόλοι ομάδας είναι ενδεικτικοί. Αναλόγως του μεγέθους της ομάδας σας, αναμένεται ότι κάποια μέλη θα έχουν σύνθετους ρόλους (π.χ., υπεύθυνος εργασίας και frontend developer). Η κατανομή των ρόλων είναι υπευθυνότητα της ομάδας και αντικατοπτρίζει τη λειτουργικότητα μιας ομάδας σε ένα εικονικό περιβάλλον μιας data science εταιρείας.

Ρόλος	Κύριες Ευθύνες
Υπεύθυνος Εργασίας	Συντονίζει την ομάδα, διαχειρίζεται το χρονοδιάγραμμα, προεδρεύει εβδομαδιαίες συναντήσεις, εποπτεύει την τελική εκθέση.
Μηχανικός Δεδομένων	Αναλαμβάνει τη συλλογή δεδομένων, σχεδιασμό βάσης δεδομένων, ανάπτυξη data pipeline και ελέγχους ακεραιότητας.
Επιστήμονας Δεδομένων	Αναλαμβάνει τη μοντελοποίηση: διαμόρφωση χαρακτηριστικών, επιλογή μοντέλων, εκπαίδευση, αξιολόγηση και παρακολούθηση drift.
Προγραμματιστής Frontend	Κατασκευάζει και συντηρεί το dashboard ή την εφαρμογή. Εστιάζεται στην εμπειρία χρήστη και τη διαδραστικότητα.
Διασφάλιση Ποιότητας	Συντάσσει και συντηρεί τεκμηρίωση, διαχειρίζεται το repository, συντονίζει τον έλεγχο του πρωτότυπου.

Τα καλύτερα data science projects δεν απαντούν απλώς σε μια ερώτηση, διηγούνται μια ιστορία. Κάντε τη δική σας ιστορία συναρπαστική!

Καλή επιτυχία και καλή διασκέδαση!

Σημαντικό: Για οποιαδήποτε απορία ή διευκρίνηση για οποιοδήποτε θέμα χρειάζεστε κατά τη διάρκεια της υλοποίησης της εργασίας αυτής, καλείστε να επικοινωνείτε έγκαιρα με τον υπεύθυνο καθηγητή!